

Laporan Kemajuan Proyek
Pembelajaran Mesin
S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Alya Nabila Tamam 24031554099
Anggota 1	Fina Nihayatul Husna 24031554022
Anggota 2	Juli Yawati Manalu 24031554050
URL Github	https://github.com/alyanabilatamam/Projek-Machine-Learning

Informasi Umum Proyek

Judul	Klasifikasi Penyakit Daun Padi Menggunakan Ekstraksi Fitur MobileNetV3 dan Random Forest untuk Mendukung Pertanian Berkelanjutan
Topik	Pangan
Pilihan Rumusan Masalah	1.3 Dampak Perubahan Iklim dan Rendahnya Adopsi Pertanian Berkelanjutan
Revisi	Ya

Informasi Detil Dataset

Sumber dataset	Dataset yang digunakan dalam proyek ini bersumber dari repositori publik Kaggle yang bisa diakses melalui: Rice Leaf Disease: An Images Dataset . Proses akuisisi dilakukan dengan mengunduh data secara sekunder dimana data terdiri dari lebih kurang 30.000 citra digital daun padi. Data dikumpulkan dari berbagai sumber primer (lapangan dan laboratorium) untuk memastikan variasi kondisi pencahayaan dan latar belakang yang kemudian dikumpulkan dalam struktur folder sesuai label penyakitnya.		
Deskripsi awal fitur dataset	Dataset yang digunakan merupakan dataset citra (<i>image dataset</i>), bukan dataset tabular. Setiap data berupa file gambar daun padi yang telah dikelompokkan berdasarkan jenis penyakit tertentu. Adapun atribut awal pada dataset dijelaskan sebagai berikut:		
	Tabel 1. Deskripsi Fitur Dataset		
	Atribut	Tipe Data	Deskripsi
	File Citra	Image (JPG/PNG)	Foto daun padi dalam format citra digital dengan resolusi yang bervariasi. Pada tahap preprocessing, seluruh citra akan diubah ukurannya menjadi 224 × 224 piksel agar sesuai dengan input MobileNetV3.
	Label Kelas	Categorical (String)	Label kategori penyakit daun padi, seperti <i>Bacterial Leaf Blight</i> , <i>Brown Spot</i> , <i>Leaf Blast</i> , <i>Leaf Scald</i> , <i>Hispa</i> , <i>Narrow Brown Spot</i> , dan <i>Healthy</i> .
	Nama File	String	Nama unik untuk setiap file citra yang digunakan sebagai identitas data.
	Dimensi Piksel	Integer × Integer	Ukuran resolusi gambar dalam satuan piksel (lebar × tinggi)

	sebelum preprocessing. Channel Warna Integer Jumlah kanal warna pada citra, yaitu RGB (<i>Red, Green, Blue</i>) dengan 3 channel warna. Direktori Kelas Folder/Path Struktur folder dataset yang mengelompokkan citra berdasarkan kelas penyakit untuk mempermudah proses loading data menggunakan framework deep learning.
Detil-detil langkah pre-processing	Pada penelitian ini dilakukan beberapa tahapan preprocessing untuk mempersiapkan citra daun padi sebelum digunakan pada proses ekstraksi fitur dan klasifikasi. Tahapan preprocessing bertujuan untuk meningkatkan kualitas data, memperbanyak variasi citra, serta menyesuaikan input dengan kebutuhan model MobileNetV3. 1. Loading Dataset Pada tahap awal, dataset citra daun padi diunduh dari platform Kaggle menggunakan library kagglehub. Dataset kemudian diekstrak secara otomatis ke dalam direktori lokal dan disusun berdasarkan folder masing-masing kelas penyakit. Struktur folder tersebut mempermudah proses pembacaan data karena label kelas dapat dikenali langsung dari nama direktori. 2. Struktur dan Organisasi Data Dataset terdiri dari 18 kelas citra daun padi yang mencakup berbagai jenis penyakit akibat bakteri, jamur, virus, hama, serta kelas daun sehat (<i>Healthy</i>). Setiap folder merepresentasikan satu kelas penyakit sehingga proses labeling dapat dilakukan secara otomatis tanpa pelabelan manual. 3. Resizing Citra Seluruh citra pada dataset diubah ukurannya menjadi 224×224 piksel. Proses ini dilakukan agar seluruh data memiliki ukuran yang seragam dan sesuai dengan arsitektur input MobileNetV3. Selain itu, standarisasi ukuran citra membantu meningkatkan efisiensi komputasi selama proses pelatihan model. 4. Normalisasi Data Normalisasi citra dilakukan menggunakan fungsi <code>preprocess_input</code> dari MobileNetV3. Fungsi ini menyesuaikan distribusi nilai piksel agar sesuai dengan standar data pada model pre-trained ImageNet, sehingga proses ekstraksi fitur dapat berjalan lebih optimal dan konsisten. 5. Data Augmentation Untuk meningkatkan variasi data dan membantu model melakukan generalisasi dengan lebih baik, dilakukan augmentasi data pada data training menggunakan ImageDataGenerator. Teknik augmentasi yang diterapkan meliputi: • Rotation sebesar 20 derajat • Horizontal flip • Vertical flip • Zoom sebesar 20% • Shear transformation • Brightness adjustment Proses augmentasi ini bertujuan untuk membuat model lebih robust terhadap variasi kondisi citra, seperti perubahan sudut pengambilan gambar, pencahayaan, dan orientasi daun. 6. Pembagian Dataset Dataset dibagi menjadi dua bagian, yaitu data latih dan data validasi dengan rasio 80:20. Pembagian data dilakukan secara otomatis sehingga model dapat dilatih dan dievaluasi menggunakan data yang berbeda untuk mengukur kemampuan generalisasi model. 7. Pembentukan Data Generator

	Data kemudian dimuat menggunakan fungsi <code>flow_from_directory()</code>. Fungsi ini secara otomatis membaca citra berdasarkan struktur folder kelas, melakukan preprocessing, serta memproses data dalam bentuk batch agar penggunaan memori menjadi lebih efisien selama proses ekstraksi fitur dan pelatihan model. 8. Encoding Label Label kelas dihasilkan secara otomatis berdasarkan nama folder masing-masing kelas penyakit. Setiap kelas dikonversi ke dalam bentuk numerik sehingga dapat digunakan langsung pada proses klasifikasi menggunakan algoritma Random Forest. Secara keseluruhan, tahap preprocessing mencakup proses loading dataset, pengaturan struktur data, resize citra, normalisasi, augmentasi data, pembagian dataset, pembentukan data generator, dan encoding label. Seluruh tahapan tersebut dilakukan untuk memastikan dataset siap digunakan pada proses ekstraksi fitur menggunakan MobileNetV3 dan klasifikasi menggunakan Random Forest.
--	--

Kemajuan Pengerjaan


Teknik yang digunakan	Pada penelitian ini digunakan pendekatan <i>supervised learning</i> dengan kombinasi metode <i>deep learning</i> dan <i>machine learning</i>. Teknik utama yang digunakan yaitu <i>transfer learning</i> menggunakan arsitektur MobileNetV3 sebagai <i>feature extractor</i> dan algoritma Random Forest sebagai model klasifikasi berbasis <i>ensemble learning</i>. MobileNetV3 Large digunakan untuk mengekstraksi fitur penting dari citra daun padi. Model ini memanfaatkan bobot <i>pre-trained</i> dari ImageNet sehingga mampu menghasilkan representasi fitur visual yang lebih efektif tanpa perlu melakukan pelatihan CNN dari awal. Pada implementasinya, lapisan klasifikasi akhir pada MobileNetV3 dihapus (<code>include_top=False</code>) dan output akhir menggunakan <i>Global Average Pooling</i> sehingga menghasilkan <i>feature vector</i> berdimensi 960 untuk setiap citra. Fitur hasil ekstraksi kemudian digunakan sebagai input bagi algoritma Random Forest untuk melakukan klasifikasi multi-kelas terhadap 18 kategori penyakit daun padi. Random Forest dipilih karena memiliki kemampuan yang baik dalam menangani data berdimensi tinggi, relatif tahan terhadap overfitting, serta mampu memberikan performa yang stabil pada proses klasifikasi. Kombinasi MobileNetV3 dan Random Forest diharapkan mampu menghasilkan model klasifikasi yang akurat, efisien, dan memiliki kebutuhan komputasi yang lebih ringan dibandingkan pelatihan CNN secara end-to-end.										
Nilai metrik terakhir	Berdasarkan hasil evaluasi model klasifikasi penyakit daun padi menggunakan kombinasi MobileNetV3 dan Random Forest, diperoleh hasil performa sebagai berikut: <table><caption>Tabel 2. Hasil Evaluasi Model</caption><tr><th>Evaluasi Model</th><th>Accuracy</th><th>Precision</th><th>Recall</th><th>F1-Score</th></tr><tr><td>Nilai</td><td>67.8%</td><td>0.75</td><td>0.55</td><td>0.56</td></tr></table> Hasil evaluasi menunjukkan bahwa model mampu mencapai tingkat akurasi sebesar 67.8% dalam melakukan klasifikasi terhadap 18 kelas penyakit daun padi. Nilai precision yang relatif tinggi menunjukkan bahwa sebagian besar prediksi yang diberikan model sudah cukup tepat. Namun, nilai recall dan F1-score yang masih lebih rendah menunjukkan bahwa model belum mampu mengenali seluruh kelas secara merata, terutama pada kelas minoritas yang memiliki jumlah data lebih sedikit. Kondisi tersebut dipengaruhi oleh distribusi dataset yang tidak seimbang (<i>imbalanced dataset</i>) serta kemiripan karakteristik visual antar beberapa jenis penyakit daun padi. Meskipun demikian, kombinasi MobileNetV3 dan Random Forest sudah menunjukkan performa awal yang cukup baik untuk proses klasifikasi multi-kelas.	Evaluasi Model	Accuracy	Precision	Recall	F1-Score	Nilai	67.8%	0.75	0.55	0.56
Evaluasi Model	Accuracy	Precision	Recall	F1-Score							
Nilai	67.8%	0.75	0.55	0.56							
Visualisasi grafik latih dan validasi	Pada penelitian ini tidak dilakukan proses pelatihan model secara <i>end-to-end</i> menggunakan Convolutional Neural Network (CNN). Pendekatan yang digunakan yaitu <i>feature extraction</i> menggunakan MobileNetV3 pre-trained, kemudian hasil fitur diklasifikasikan menggunakan algoritma Random Forest. Oleh karena itu, penelitian										

ini tidak menghasilkan grafik *training loss*, *validation loss*, maupun *accuracy per epoch* seperti pada pelatihan CNN konvensional.

Sebagai pengganti grafik pelatihan, evaluasi model dilakukan menggunakan *confusion matrix* dan *classification report* pada data validasi. Visualisasi tersebut digunakan untuk menganalisis performa model dalam mengklasifikasikan setiap kelas penyakit daun padi secara lebih detail.

Confusion matrix digunakan untuk melihat distribusi hasil prediksi antara kelas aktual dan kelas prediksi. Berdasarkan hasil visualisasi, beberapa kelas dengan jumlah data yang besar menunjukkan performa prediksi yang lebih baik dibandingkan kelas dengan jumlah data yang sedikit. Hal ini menunjukkan bahwa ketidakseimbangan distribusi data (*imbalanced dataset*) masih memengaruhi kemampuan model dalam mengenali seluruh kelas secara merata.

Selain itu, *classification report* digunakan untuk menampilkan nilai precision, recall, dan F1-score pada masing-masing kelas sehingga dapat diketahui kelas mana yang memiliki performa klasifikasi terbaik maupun yang masih mengalami kesalahan prediksi cukup tinggi.



Gambar 1. Confusion Matrix

Berdasarkan hasil evaluasi model, ditemukan bahwa performa klasifikasi belum merata pada seluruh kelas penyakit daun padi. Beberapa kelas dengan jumlah data yang besar seperti *Brown Spot*, *Bacterial Blight*, dan *Tungro* menunjukkan performa klasifikasi yang cukup baik dengan nilai precision dan recall yang tinggi. Sebaliknya, beberapa kelas minoritas seperti *Sheath Rot*, *Bacterial Streak*, dan *Hispa* masih memiliki performa yang rendah, bahkan mendekati nol pada beberapa metrik evaluasi.

Hasil tersebut menunjukkan adanya permasalahan *class imbalance* pada dataset, dimana model cenderung lebih mudah mempelajari pola pada kelas mayoritas dibandingkan kelas minoritas. Selain itu, kemiripan karakteristik visual antar beberapa jenis penyakit daun padi juga menyebabkan model mengalami kesulitan dalam membedakan kelas tertentu.

Pada penelitian ini belum ditemukan indikasi overfitting yang signifikan, namun performa model masih perlu ditingkatkan terutama pada kemampuan generalisasi terhadap kelas minoritas. Oleh karena itu, proses pengembangan selanjutnya akan difokuskan pada *hyperparameter tuning* pada algoritma Random Forest, seperti pengaturan jumlah pohon (*n_estimators*), kedalaman pohon (*max_depth*), dan parameter lainnya untuk meningkatkan performa klasifikasi model secara keseluruhan. Selain itu, akan dilakukan evaluasi tambahan terhadap strategi penanganan data tidak seimbang untuk meningkatkan kemampuan model dalam mengenali seluruh kelas penyakit secara lebih merata.

Temuan